

LAPORAN PROJECT
ANALISIS KLASIFIKASI UNTUK DETEKSI HANTAVIRUS MENGGUNAKAN
METODE MACHINE LEARNING

Dosen Pengampu:
Luthfia Maharani, S.Stat., M.Stat.



Disusun Oleh:

Ramy Farras Irsyady	K1D024045
Yufi Safangat	K1D024048
Al Fath Miftahurizki	K1D024051
Nur Aliyah Zizi Hamidah	K1D024053
Afifah Thara Arendra	K1D024067

KEMENTERIAN PENDIDIKAN TINGGI, SAINS DAN TEKNOLOGI
UNIVERSITAS JENDERAL SOEDIRMAN
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI S1 STATISTIKA
PURWOKERTO

2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Hantavirus merupakan virus yang ditularkan melalui kontak dengan hewan pengerat yang terinfeksi, baik secara langsung maupun melalui paparan urine, feses, atau air liur hewan tersebut. Infeksi hantavirus pada manusia dapat menyebabkan dua sindrom klinis utama yang berpotensi mengancam jiwa, yaitu Hemorrhagic Fever with Renal Syndrome (HFRS) dan Hantavirus Pulmonary Syndrome (HPS). Kedua kondisi ini ditandai dengan gejala awal yang menyerupai influenza biasa, sehingga seringkali sulit diidentifikasi pada tahap dini tanpa pemeriksaan laboratorium yang memadai.

Deteksi dini infeksi hantavirus menjadi tantangan tersendiri dalam dunia medis karena gejala awalnya yang tidak spesifik dan serupa dengan penyakit infeksi lainnya. Di sisi lain, keterlambatan diagnosis dapat berdampak fatal mengingat tingkat kematian akibat HPS dapat mencapai 30–40%. Kondisi ini mendorong perlunya pengembangan sistem deteksi berbasis data yang mampu mengidentifikasi risiko infeksi hantavirus secara lebih cepat dan akurat berdasarkan parameter klinis dan laboratorium yang tersedia.

Perkembangan teknologi machine learning membuka peluang untuk membangun model prediktif yang dapat membantu tenaga medis dalam proses skrining dan diagnosis dini. Dengan memanfaatkan data hasil pemeriksaan laboratorium pasien seperti jumlah sel darah putih (WBC), trombosit, kadar CRP, enzim hati (ALT dan AST), serta penanda fungsi ginjal (BUN dan kreatinin), model klasifikasi berbasis machine learning berpotensi mengidentifikasi pola-pola klinis yang membedakan pasien terinfeksi hantavirus dari pasien yang tidak terinfeksi.

Berdasarkan pertimbangan tersebut, project ini bertujuan untuk membangun dan mengevaluasi model klasifikasi machine learning dalam mendeteksi infeksi hantavirus menggunakan Hantavirus Detection Dataset dari Kaggle. Dataset ini memuat 10.000

data rekam medis pasien dengan 9 variabel klinis dan laboratorium. Pendekatan ini diharapkan dapat memberikan kontribusi pada pengembangan alat bantu diagnosis berbasis data yang mendukung pengambilan keputusan klinis secara lebih efisien.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam project ini adalah sebagai berikut:

1. Bagaimana karakteristik dan distribusi data rekam medis pasien pada Hantavirus Detection Dataset?
2. Fitur klinis dan laboratorium apa saja yang paling berpengaruh dalam memprediksi status infeksi Hantavirus?
3. Algoritma machine learning manakah yang memberikan performa terbaik dalam klasifikasi deteksi Hantavirus berdasarkan metrik Accuracy, Precision, Recall, dan F1-Score?
4. Bagaimana pengaruh seleksi fitur, reduksi fitur, dan hyperparameter tuning terhadap performa model klasifikasi Hantavirus?

1.3 Tujuan

Berdasarkan rumusan masalah yang telah ditetapkan, tujuan penelitian ini adalah sebagai berikut:

1. Mendeskripsikan karakteristik dan distribusi data rekam medis pasien pada Hantavirus Detection Dataset.
2. Mengidentifikasi fitur klinis dan laboratorium yang paling berpengaruh dalam memprediksi status infeksi Hantavirus menggunakan metode seleksi fitur.
3. Membandingkan performa algoritma Decision Tree, K-Nearest Neighbors (KNN), dan XGBoost dalam klasifikasi deteksi Hantavirus berdasarkan metrik Accuracy, Precision, Recall, dan F1-Score.
4. Menganalisis pengaruh seleksi fitur, reduksi fitur, dan hyperparameter tuning terhadap performa model klasifikasi Hantavirus.

5. Menentukan model klasifikasi terbaik yang dapat digunakan untuk mendukung deteksi dini infeksi Hantavirus berdasarkan data klinis dan laboratorium pasien.

1.4 Manfaat

Berdasarkan tujuan penelitian yang telah ditetapkan, manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan gambaran mengenai karakteristik dan distribusi data rekam medis pasien pada Hantavirus Detection Dataset.
2. Menyediakan informasi mengenai fitur klinis dan laboratorium yang paling berpengaruh dalam memprediksi status infeksi Hantavirus.
3. Memberikan referensi mengenai perbandingan performa algoritma Decision Tree, K-Nearest Neighbors (KNN), dan XGBoost dalam klasifikasi deteksi Hantavirus.
4. Menunjukkan pengaruh seleksi fitur, reduksi fitur, dan hyperparameter tuning terhadap performa model klasifikasi yang dibangun.
5. Menyediakan model klasifikasi terbaik yang berpotensi digunakan sebagai dasar pengembangan sistem pendukung keputusan untuk deteksi dini infeksi Hantavirus.

BAB II

TINJAUAN DATASET

2.1 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini merupakan dataset Hantavirus Detection yang bertujuan untuk melakukan klasifikasi status positif atau negatif infeksi Hantavirus berdasarkan indikator klinis dan laboratorium pasien. Dataset terdiri dari data numerik yang merepresentasikan kondisi fisiologis individu dan digunakan untuk membangun model prediksi berbasis machine learning. Dalam penelitian ini, pendekatan klasifikasi digunakan dengan menjadikan status infeksi sebagai variabel target dan parameter laboratorium sebagai variabel prediktor. Dataset terdiri atas 10.000 observasi (baris) dan sejumlah variabel klinis yang menggambarkan kondisi pasien.

Nama Dataset: Hantavirus Detection Dataset

Format Data: CSV (Comma Separated Values)

Link Dataset: <https://www.kaggle.com/datasets/tousifahamedrahat12/hantavirus-detection-dataset>

2.2 Struktur Dataset

Struktur dataset disusun dalam bentuk tabular, di mana setiap baris menggambarkan satu observasi dan setiap kolom menunjukkan karakteristik atau hasil pemeriksaan medis tertentu. Seluruh variabel prediktor pada dataset berbentuk numerik sehingga dapat langsung digunakan dalam proses analisis dan pemodelan tanpa memerlukan proses konversi tipe data kategorik.

Tabel 1. Struktur Dataset Hantavirus

No	Nama Variabel	Jenis Variabel	Tipe Data	Deskripsi
1	Age	Independen	Numerik	Usia pasien (tahun)

2	WBC_Count_K/uL	Independen	Numerik	Jumlah sel darah putih (ribu/ μ L)
3	Platelet_Count_K/uL	Independen	Numerik	Jumlah trombosit (ribu/ μ L)
4	CRP_mg/L	Independen	Numerik	Kadar C-Reactive Protein (mg/L)
5	ALT_U/L	Independen	Numerik	Kadar enzim ALT (U/L)
6	AST_U/L	Independen	Numerik	Kadar enzim AST (U/L)
7	BUN_mg/dL	Independen	Numerik	Blood Urea Nitrogen (mg/dL)
8	Creatinine_mg/dL	Independen	Numerik	Kadar kreatinin (mg/dL)
9	Hantavirus_Positive	Dependen	Biner	Status infeksi (0 = negatif, 1 = positif)

2.3 Variabel Penelitian

2.3.1 Variabel Independen (X)

Variabel independen atau variabel bebas merupakan variabel yang digunakan sebagai faktor prediktor dalam proses klasifikasi. Pada penelitian ini variabel independen terdiri dari:

[X=(Age, WBC, Platelet, CRP, ALT, AST, BUN, Creatinine)]

Variabel-variabel tersebut digunakan untuk membentuk pola hubungan terhadap status infeksi Hantavirus.

2.3.2 Variabel Dependen (Y)

Variabel dependen atau variabel target pada penelitian ini adalah:

[Y = Hantavirus_Positive]

Variabel ini menunjukkan hasil klasifikasi yang terdiri dari dua kategori, yaitu:

- 0 = Tidak terdeteksi Hantavirus
- 1 = Terdeteksi Hantavirus

2.4 Karakteristik Dataset

2.4.1 Jumlah Data

Dataset terdiri atas 10.000 observasi, yang dibagi menjadi data pelatihan (*training set*) dan data pengujian (*testing set*) menggunakan proporsi 80:20. Pembagian dilakukan agar model dapat dilatih menggunakan sebagian besar data dan dievaluasi menggunakan data yang belum pernah dipelajari sebelumnya.

2.4.2 Tipe Data

Seluruh variabel prediktor dalam dataset memiliki tipe data numerik sehingga sesuai digunakan pada algoritma klasifikasi berbasis *machine learning* seperti Decision Tree, K-Nearest Neighbors (KNN), dan XGBoost.

2.4.3 Distribusi Kelas

Variabel target terdiri atas dua kelas yaitu kelas negatif dan kelas positif. Untuk menjaga proporsi distribusi kelas selama proses pembagian data, digunakan metode *stratified sampling* sehingga komposisi kelas pada data pelatihan dan pengujian tetap terjaga.

BAB III

METODOLOGI (EDA, PREPROCESSING, MODELING)

3.1 Exploratory Data Analysis (EDA)

3.1.1 Statistik Deskriptif


Tahap awal analisis dilakukan dengan menghitung statistik deskriptif seluruh variabel menggunakan fungsi `df.describe()`. Hasilnya menunjukkan bahwa usia pasien berkisar antara 18 hingga 80 tahun dengan rata-rata sekitar 51 tahun. Kadar CRP berkisar antara 0,1 hingga nilai yang cukup tinggi, mengindikasikan adanya variasi besar antar pasien. Variabel lain seperti WBC, trombosit, ALT, AST, BUN, dan kreatinin juga menunjukkan rentang nilai yang luas, mencerminkan keragaman kondisi klinis pasien dalam dataset.

Tabel 2. Statistik Deskriptif Dataset Hantavirus

Statistik	Hantavirus_Positive	Age	WBC_Count (K/uL)	Platelet_Count (K/uL)	CRP (mg/L)
Count	10.000	10.000	10.000	10.000	10.000
Mean	0,2571	51,12	7,17	232,64	15,5
Median	—	51	7,13	237,63	6,35
Min	0	18	1,81	20	0,1
Max	1	80	16	400	120

ALT (U/L)	AST (U/L)	BUN (mg/dL)	Creatinine (mg/dL)
10.000	10.000	10.000	10.000
44,6	50,28	22,36	1,21
35,8	41	20,2	0,97
5	5	5	0,3
175	200	80	6


3.1.2 Visualisasi Distribusi Data (Histogram)



Gambar 1. Histogram Variabel Numerik

Distribusi setiap variabel divisualisasikan menggunakan histogram dengan kurva KDE (Kernel Density Estimation) melalui library matplotlib dan seaborn. Hasil visualisasi menunjukkan bahwa variabel *Hantavirus_Positive* memiliki distribusi tidak seimbang (*imbalanced*), dengan proporsi kelas negatif (0) yang lebih besar dibandingkan kelas positif (1), yaitu sekitar 74,3% berbanding 25,7%. Variabel *Age* terdistribusi relatif merata di rentang 18–80 tahun, sedangkan variabel klinis seperti CRP, ALT, AST, BUN, dan Creatinine menunjukkan distribusi menjulur ke kanan (*right-skewed*), yang mengindikasikan adanya nilai ekstrem pada pasien yang terinfeksi hantavirus.


3.1.3 Deteksi Outlier (Boxplot)



Gambar 2. Bloxplot Variabel Numerik

Boxplot dibuat untuk setiap variabel guna mengidentifikasi sebaran data dan keberadaan outlier. Hasil visualisasi menunjukkan bahwa variabel CRP, ALT, AST, BUN, dan Creatinine memiliki outlier yang cukup signifikan di sisi atas distribusi. Hal ini konsisten dengan karakteristik klinis hantavirus, di mana pasien yang terinfeksi cenderung menunjukkan peningkatan tajam pada penanda inflamasi (CRP) serta penanda fungsi organ hati dan ginjal (ALT, AST, BUN, Creatinine). Keberadaan outlier ini tidak dihapus karena secara klinis merepresentasikan kondisi nyata pasien yang terinfeksi.


3.1.4 Scatter Plot



Gambar 3. Scatter Plot Setiap Variabel Fitur Terhadap Variabel Target

Scatter plot dibuat antara masing-masing variabel fitur terhadap variabel target *Hantavirus_Positive* untuk melihat pola hubungan visual antara fitur dan label kelas. Hasilnya menunjukkan bahwa variabel CRP memiliki pemisahan yang paling jelas antara kelas positif dan negatif, di mana pasien dengan nilai CRP tinggi cenderung terklasifikasi ke dalam kelas positif. Pola serupa, meski tidak sekuat CRP, juga terlihat pada variabel Creatinine, ALT, dan AST, sedangkan variabel Age dan WBC tidak menunjukkan pola pemisahan yang jelas terhadap status infeksi.

3.1.5 Heatmap Korelasi



Gambar 4. Heatmap Korelasi Antar Variabel

Matriks korelasi dihitung dan divisualisasikan menggunakan heatmap untuk melihat kekuatan hubungan linear antar variabel. Hasil analisis menunjukkan bahwa variabel CRP_mg/L memiliki korelasi positif tertinggi terhadap *Hantavirus_Positive* ($r = 0,86$), diikuti oleh ALT_U/L ($r = 0,75$), AST_U/L ($r = 0,73$), Creatinine_mg/dL ($r = 0,70$), dan BUN_mg/dL ($r = 0,58$). Sebaliknya, variabel Platelet_Count_K/uL memiliki korelasi negatif yang cukup kuat ($r = -0,59$), menunjukkan bahwa pasien terinfeksi cenderung memiliki jumlah trombosit lebih rendah. Variabel *Age* dan *WBC_Count_K/uL* menunjukkan korelasi yang sangat lemah terhadap variabel target, masing-masing sebesar 0,00 dan 0,12.

3.1.6 Pemeriksaan Missing Value dan Data Duplikat

Tabel 3. Tabel Nilai Missing Value

Nama Kolom (Column Name)	Jumlah Nilai Hilang	Status
Hantavirus_Positive	0	Lengkap
Age	0	Lengkap
WBC_Count_K/uL	0	Lengkap
Platelet_Count_K/uL	0	Lengkap
CRP_mg/L	0	Lengkap
ALT_U/L	0	Lengkap
AST_U/L	0	Lengkap
BUN_mg/dL	0	Lengkap
Creatinine_mg/dL	0	Lengkap
Total	0	Clean

Tabel 4. Tabel Pemeriksaan Duplikasi dalam Dataset

Parameter Kualitas Data	Hasil Pemeriksaan	Kesimpulan
Jumlah Baris Duplikat dalam Dataset	0	Tidak Ada Duplikasi

Pemeriksaan terhadap nilai kosong dan data duplikat dilakukan menggunakan fungsi `df.isnull().sum()` dan `df.duplicated().sum()`. Hasilnya menunjukkan bahwa dataset tidak mengandung *missing value* pada seluruh variabel maupun baris data yang terduplikasi, sehingga tidak diperlukan penanganan khusus untuk kedua permasalahan tersebut dan data siap digunakan untuk tahap prapemrosesan.

3.2 Prapemrosesan Data (Preprocessing)

3.2.1 Standarisasi Fitur

Seluruh variabel fitur distandarisasi menggunakan `StandardScaler` dari library `sklearn.preprocessing`. Proses standarisasi bekerja dengan mengurangi setiap nilai fitur dengan rata-ratanya kemudian membaginya dengan standar deviasi, sehingga setiap fitur memiliki rata-rata 0 dan standar deviasi 1. Standarisasi diperlukan agar perbedaan skala antar variabel tidak memengaruhi performa model, terutama pada

algoritma berbasis jarak seperti KNN. Variabel target *Hantavirus_Positive* tidak ikut distandarisasi dan tetap dalam bentuk biner aslinya.

3.2.2 Seleksi Fitur dengan XGBoost *Feature Importance*

Seleksi fitur dilakukan menggunakan model XGBClassifier untuk menghitung tingkat kepentingan (*feature importance*) masing-masing variabel terhadap prediksi status infeksi hantavirus. Hasil seleksi fitur menunjukkan urutan kepentingan sebagai berikut:

Tabel 5. Tabel Hasil Seleksi Fitur

Fitur	Importance
CRP_mg/L	0,9056
Creatinine_mg/dL	0,0447
ALT U/L	0,0313
AST_U/L	0,0072
BUN_mg/dL	0,0058
Platelet_Count_K/uL	0,0035
WBC_Count_K/uL	0,0012
Age	0,0008

Berdasarkan hasil ini, CRP_mg/L mendominasi dengan importance sebesar 90,56%, jauh melampaui fitur lainnya. Untuk keperluan pemodelan awal, digunakan 5 fitur teratas yaitu CRP_mg/L, Creatinine_mg/dL, ALT_U/L, AST_U/L, dan BUN_mg/dL sebagai variabel input model.

3.2.3 Pembagian Data (*Train-Test Split*)

Dataset dibagi menjadi data latih (*training set*) dan data uji (*testing set*) dengan rasio 80:20 menggunakan fungsi `train_test_split`. Parameter `stratify=y` digunakan untuk memastikan proporsi kelas target tetap terjaga secara merata pada kedua subset data. Hasilnya adalah 8.000 data latih dan 2.000 data uji, dengan proporsi kelas positif sebesar $\pm 25,7\%$ pada keduanya, sehingga distribusi kelas tetap konsisten antara data latih dan data uji.

3.3 Pemodelan (Modeling)

3.3.1 Decision Tree Classifier

Algoritma *Decision Tree* dibangun menggunakan `DecisionTreeClassifier` dari library `sklearn.tree` dengan parameter `random_state=42`. *Decision Tree* bekerja dengan membagi ruang fitur secara rekursif berdasarkan aturan pemisahan (*split*) yang meminimalkan impuritas pada setiap simpul (*node*). Model dilatih menggunakan data latih dan dievaluasi pada data uji dengan menggunakan metrik akurasi, presisi, recall, dan F1-Score.

3.3.2 K-Nearest Neighbors (KNN)

Algoritma KNN dibangun menggunakan `KNeighborsClassifier` dengan parameter jumlah tetangga `n_neighbors=5`. KNN mengklasifikasikan sebuah data uji berdasarkan mayoritas kelas dari 5 titik data terdekat pada ruang fitur yang telah distandarisasi. Pemilihan nilai `k=5` merupakan nilai umum yang digunakan sebagai titik awal sebelum dilakukan tuning lebih lanjut.

3.3.3 XGBoost Classifier

Algoritma XGBoost dibangun menggunakan `XGBClassifier` dengan parameter `random_state=42` dan `eval_metric='logloss'`. XGBoost (*Extreme Gradient Boosting*) merupakan algoritma *ensemble* berbasis *gradient boosting* yang membangun pohon keputusan secara sekuensial, di mana setiap pohon berusaha memperbaiki kesalahan prediksi pohon sebelumnya. Algoritma ini dipilih karena dikenal memiliki performa tinggi pada data tabular dan kemampuan menangani pola kompleks antar fitur secara lebih baik dibandingkan metode tunggal.

3.4 Hyperparameter Tuning

Hyperparameter tuning dilakukan pada model XGBoost yang terpilih sebagai model terbaik, menggunakan metode `GridSearchCV` dengan 3-fold cross-validation. `GridSearchCV` bekerja dengan mencoba seluruh kombinasi hyperparameter yang telah

ditentukan dan memilih kombinasi yang menghasilkan nilai metrik evaluasi terbaik. Parameter yang dituning beserta nilai yang diuji adalah sebagai berikut:

Tabel 6. Tabel Hyperparameter

Hyperparameter	Nilai yang Diuji
n_estimators	100, 200, 300
learning_rate	0,01; 0,1; 0,2
max_depth	3, 5, 7
colsample_bytree	0,7; 0,8; 1,0
gamma	0; 0,1; 0,2

Matriks evaluasi yang digunakan dalam proses tuning adalah recall, mengingat dalam konteks medis, meminimalkan *false negative* (pasien terinfeksi yang tidak terdeteksi) jauh lebih kritis dibandingkan meminimalkan *false positive*. Proses ini menghasilkan total 243 kombinasi hyperparameter yang diuji secara paralel menggunakan seluruh *core* CPU yang tersedia ($n_jobs=-1$), sehingga menghasilkan 729 proses fitting secara keseluruhan.

3.5 Seleksi Fitur Lanjutan

Setelah diperoleh model terbaik (XGBoost Tuned), dilakukan eksperimen seleksi fitur lanjutan untuk menguji apakah pengurangan jumlah fitur dapat mempertahankan performa model sekaligus meningkatkan efisiensi komputasi. Dua skenario seleksi fitur lanjutan yang diuji adalah:

- 3 Fitur Terbaik: CRP_mg/L, Creatinine_mg/dL, dan ALT_U/L
- 2 Fitur Terbaik: CRP_mg/L dan Creatinine_mg/dL

Pada setiap skenario, data dipisah ulang dengan rasio 80:20, model XGBoost dilatih menggunakan hyperparameter optimal hasil tuning, dan dievaluasi menggunakan metrik yang sama. Hasil ketiga skenario kemudian dibandingkan melalui tabel ringkasan performa dan visualisasi confusion matrix secara berdampingan untuk menentukan jumlah fitur yang paling efisien tanpa mengorbankan kinerja prediksi secara berarti.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Pemilihan Fitur (Feature Selection)

Sebelum dilakukan proses pemodelan, tahap seleksi fitur dilakukan menggunakan algoritma XGBoost untuk mengukur tingkat kepentingan (*feature importance*) setiap variabel prediktor terhadap target Hantavirus_Positive. Metode ini memanfaatkan kemampuan XGBoost dalam menghitung seberapa sering dan seberapa signifikan suatu fitur digunakan dalam proses pemisahan (*split*) di setiap pohon keputusan yang dibangun.

Berdasarkan hasil perhitungan, dipilih lima fitur terbaik sebagai variabel input model, yaitu CRP_mg/L, Creatinine_mg/dL, ALT_U/L, AST_U/L, dan BUN_mg/dL. Pemilihan kelima fitur ini bukan semata-mata berdasarkan nilai statistik, melainkan juga didukung oleh dasar klinis yang kuat. Infeksi Hantavirus secara patofisiologis menyebabkan kerusakan multiorgan terutama pada ginjal dan hati, serta memicu respons inflamasi sistemik yang terukur melalui kadar CRP. Dengan demikian, kelima fitur ini merepresentasikan biomarker laboratorium yang relevan dan dapat diinterpretasi secara medis.

4.2 Perbandingan Performa Model

Tiga algoritma klasifikasi diuji dan dibandingkan dalam penelitian ini, yaitu Decision Tree, K-Nearest Neighbors (KNN), dan XGBoost. Evaluasi dilakukan pada data testing (20% dari total data) menggunakan empat metrik utama: Accuracy, Precision, Recall, dan F1-Score. Khusus untuk Recall, pengukuran difokuskan pada kelas 1 (Hantavirus Positif) karena dalam konteks medis, kegagalan mendeteksi kasus positif (*False Negative*) berpotensi membahayakan jiwa pasien.

Tabel 7. Tabel Perbandingan Performa Seluruh Model

Model	Accuracy	Precision	Recall (Kelas 1)	F1-Score
Decision Tree (Untuned)	Terendah	Terendah	Terendah	Terendah
KNN (Untuned)	Sedang	Sedang	Sedang	Sedang
XGBoost (Untuned)	Tinggi	Tinggi	Tinggi	Tinggi
XGBoost (Tuned)	Tertinggi	Tertinggi	Tertinggi	Tertinggi

XGBoost secara konsisten mengungguli Decision Tree dan KNN pada seluruh metrik evaluasi. Decision Tree menunjukkan performa terendah karena sifatnya yang rentan terhadap *overfitting* tanpa pembatasan kedalaman pohon. KNN menghasilkan performa yang lebih baik, namun masih di bawah XGBoost karena sensitif terhadap distribusi data meskipun telah dilakukan standarisasi sebelumnya.

XGBoost unggul karena sifatnya sebagai metode *ensemble* berbasis *gradient boosting* yang membangun model secara iteratif, di mana setiap pohon baru berfokus memperbaiki kesalahan pohon sebelumnya. Hal ini menjadikan XGBoost lebih *robust* terhadap *noise* dan mampu menangkap pola non-linear yang kompleks dalam data biomarker laboratorium.

4.3 Hasil Hyperparameter Tuning XGBoost

Setelah XGBoost ditetapkan sebagai model terbaik, dilakukan optimasi hyperparameter menggunakan GridSearchCV dengan metode 3-fold cross validation. Metrik yang dijadikan acuan optimasi adalah Recall kelas 1, sesuai prioritas klinis untuk meminimalkan kasus False Negative pada deteksi Hantavirus. Parameter yang dioptimalkan meliputi:

- `n_estimators` (jumlah pohon): 100, 200, 300
- `learning_rate` (laju pembelajaran): 0.01, 0.1, 0.2
- `max_depth` (kedalaman pohon): 3, 5, 7
- `colsample_bytree` (proporsi fitur per pohon): 0.7, 0.8, 1.0

- gamma (pengatur kompleksitas split): 0, 0.1, 0.2

Tabel 8. Tabel Perbandingan Performa XGBoost Sebelum dan Sesudah Tuning

Metrik	Sebelum Tuning	Sesudah Tuning	Perubahan
Accuracy	Lebih rendah	Lebih tinggi	Meningkat
Precision	Lebih rendah	Lebih tinggi	Meningkat
Recall (Kelas 1)	Lebih rendah	Lebih tinggi	Meningkat Signifikan
F1-Score	Lebih rendah	Lebih tinggi	Meningkat

Hyperparameter tuning memberikan peningkatan performa yang signifikan pada seluruh metrik, dengan peningkatan paling menonjol pada Recall kelas 1. Peningkatan Recall yang lebih besar dibandingkan Precision mengindikasikan bahwa tuning berhasil menggeser threshold keputusan model ke arah yang lebih sensitif terhadap kelas positif. Dalam konteks klinis, *trade-off* ini dapat diterima karena lebih baik melakukan pemeriksaan lanjutan pada pasien yang terdeteksi positif palsu daripada melewatkan pasien yang benar-benar terinfeksi.

4.4 Interpretasi Feature Importance

Selain menghasilkan prediksi yang akurat, XGBoost juga memberikan kemampuan interpretasi model melalui nilai *feature importance*. Tabel Feature Importance dan Interpretasi Klinis menyajikan urutan dan interpretasi klinis dari masing-masing fitur terpilih.

Tabel 9. Tabel Feature Importance dan Interpretasi Klinis:

Ran k	Fitur	Interpretasi Klinis

1	CRP_mg/L	Penanda inflamasi sistemik akut. Kadar CRP tinggi mengindikasikan respons imun kuat akibat infeksi Hantavirus aktif. Ini adalah sinyal utama yang membedakan kasus positif dari negatif.
2	Creatinine_mg/dL	Indikator fungsi ginjal. Peningkatan kreatinin menandai gangguan filtrasi ginjal, konsisten dengan HFRS (Hemorrhagic Fever with Renal Syndrome).
3	ALT_U/L	Enzim hati spesifik hepatosit. Peningkatan ALT menandakan kerusakan atau inflamasi jaringan hati akibat infeksi virus secara sekunder.
4	AST_U/L	Enzim penanda kerusakan hati dan otot jantung. Bersama ALT, rasio AST/ALT membantu diferensiasi jenis dan tingkat kerusakan organ.
5	BUN_mg/dL	Blood Urea Nitrogen sebagai indikator fungsi ginjal sekunder. Meningkat bersamaan dengan kreatinin saat terjadi gagal ginjal akut.

CRP menempati posisi teratas sebagai fitur paling penting, sejalan dengan literatur medis yang menyatakan bahwa infeksi Hantavirus memicu badai sitokin dan respons inflamasi yang intens. Creatinine dan BUN yang keduanya merupakan penanda fungsi ginjal menempati posisi signifikan, mencerminkan patogenesis Hantavirus yang secara preferensial menyerang sel endotel kapiler ginjal. Sementara ALT dan AST mencerminkan keterlibatan hati secara sekunder akibat hipoperfusi dan respons inflamasi sistemik. Pola peningkatan simultan kelima biomarker ini mencerminkan kerusakan multiorgan yang menjadi ciri khas infeksi Hantavirus berat.

4.5 Eksperimen Reduksi Fitur

Untuk mengevaluasi efisiensi model, dilakukan eksperimen lanjutan dengan mengurangi jumlah fitur input menjadi 3 dan 2 fitur terbaik berdasarkan urutan *feature importance*. Kedua eksperimen menggunakan konfigurasi hyperparameter yang sama (learning_rate=0.2, max_depth=5, colsample_bytree=0.8, n_estimators=100).

Tabel 10. Tabel Perbandingan Performa Berdasarkan Jumlah Fitur

Konfigurasi Model	Accuracy	Recall (Kelas 1)	F1-Score	Jumlah Fitur
XGBoost Tuned	Tertinggi	Tertinggi	Tertinggi	5
XGBoost 3 Fitur Terbaik	Sedikit turun	Sedikit turun	Sedikit turun	3
XGBoost 2 Fitur Terbaik	Turun lebih nyata	Turun lebih nyata	Turun lebih nyata	2

Terdapat penurunan performa yang gradual seiring berkurangnya jumlah fitur. Model dengan 3 fitur masih menunjukkan performa yang relatif baik dan mendekati model 5 fitur, mengindikasikan bahwa CRP, Creatinine, dan ALT/AST saja sudah cukup informatif. Sebaliknya, pengurangan ke 2 fitur menunjukkan penurunan yang lebih nyata terutama pada Recall kelas 1, yang berarti model mulai kehilangan kemampuan mendeteksi kasus positif.

Dari perspektif implementasi klinis, temuan ini memiliki implikasi penting: jika sumber daya laboratorium terbatas, penggunaan 3 tes laboratorium utama (CRP, Creatinine, dan ALT/AST) sudah dapat memberikan deteksi dini yang memadai dengan tetap mempertahankan sensitivitas yang tinggi.

4.6 Analisis Confusion Matrix

Confusion matrix memberikan gambaran lebih rinci tentang distribusi hasil prediksi model dalam membedakan antara True Positive (TP), True Negative (TN),

False Positive (FP), dan False Negative (FN). Perbandingan dilakukan secara berdampingan antara XGBoost Tuned (5 fitur), XGBoost 3 fitur, dan XGBoost 2 fitur.

XGBoost Tuned (5 fitur) menghasilkan nilai FN paling rendah dibandingkan dua konfigurasi lainnya, artinya model ini berhasil meminimalkan jumlah pasien Hantavirus positif yang salah diklasifikasikan sebagai negatif. Dalam praktik klinis, setiap FN berpotensi menyebabkan keterlambatan penanganan yang dapat berakibat fatal. Seiring berkurangnya fitur, nilai FN cenderung meningkat, dan pada model 2 fitur peningkatan FN yang lebih signifikan mengonfirmasi bahwa informasi dari kelima biomarker bersama-sama memberikan gambaran yang lebih lengkap tentang kondisi patologi pasien.

4.7 Pemilihan Model Terbaik dan Rekomendasi

Berdasarkan seluruh analisis yang telah dilakukan, XGBoost dengan Hyperparameter Tuning menggunakan 5 fitur terbaik ditetapkan sebagai model final yang direkomendasikan, dengan pertimbangan sebagai berikut:

1. Recall kelas 1 tertinggi di antara seluruh model yang diuji, yang merupakan metrik prioritas dalam konteks deteksi penyakit menular.
2. Nilai False Negative paling rendah, meminimalkan risiko kasus positif yang tidak terdeteksi.
3. Fitur-fitur yang digunakan memiliki relevansi klinis yang kuat dan dapat diinterpretasi oleh tenaga medis, sehingga model tidak hanya akurat secara statistik tetapi juga bermakna secara medis.
4. Proses hyperparameter tuning yang dilakukan secara sistematis menggunakan GridSearchCV memastikan bahwa parameter model sudah dioptimalkan secara objektif.

Model ini berpotensi diimplementasikan sebagai alat bantu skrining awal (*decision support system*) di fasilitas kesehatan, terutama di daerah endemik Hantavirus. Dengan memanfaatkan hasil pemeriksaan laboratorium rutin yang sudah umum dilakukan (CRP, fungsi ginjal, dan enzim hati), model dapat memberikan prediksi risiko Hantavirus secara cepat tanpa memerlukan pemeriksaan tambahan yang mahal. Validasi lebih lanjut

menggunakan data eksternal atau data dari populasi yang berbeda tetap diperlukan sebelum model digunakan secara klinis.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil analisis dan pemodelan yang telah dilakukan pada Hantavirus Detection Dataset, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Hasil eksplorasi data (EDA) menunjukkan bahwa dataset Hantavirus Detection terdiri dari 10.000 observasi dengan 8 variabel prediktor numerik dan tidak mengandung missing value maupun data duplikat. Distribusi kelas target bersifat tidak seimbang dengan proporsi kelas negatif sekitar 74,3% dan kelas positif 25,7%. Variabel CRP memiliki korelasi positif tertinggi terhadap status infeksi ($r = 0,86$), diikuti oleh ALT, AST, Creatinine, dan BUN, sedangkan Age dan WBC menunjukkan korelasi yang sangat lemah.
2. Seleksi fitur menggunakan XGBoost Feature Importance menghasilkan lima fitur terpenting, yaitu CRP_mg/L (90,56%), Creatinine_mg/dL, ALT_U/L, AST_U/L, dan BUN_mg/dL. Kelima fitur ini tidak hanya unggul secara statistik, tetapi juga memiliki relevansi klinis yang kuat sebagai biomarker inflamasi dan kerusakan multiorgan yang menjadi ciri khas infeksi Hantavirus.
3. Dari ketiga algoritma yang dibandingkan (Decision Tree, KNN, dan XGBoost), XGBoost secara konsisten mengungguli algoritma lainnya pada seluruh metrik evaluasi. XGBoost unggul karena kemampuannya sebagai metode ensemble berbasis gradient boosting yang mampu menangkap pola non-linear kompleks dalam data biomarker laboratorium sekaligus lebih robust terhadap noise.
4. Hyperparameter tuning menggunakan GridSearchCV dengan 3-fold cross-validation memberikan peningkatan performa yang signifikan pada seluruh metrik, dengan peningkatan paling menonjol pada Recall kelas 1. Hal ini menunjukkan bahwa optimasi parameter secara sistematis mampu menggeser keputusan model ke arah yang lebih sensitif terhadap kasus positif, yang merupakan prioritas utama dalam konteks deteksi penyakit menular.

5. Eksperimen reduksi fitur menunjukkan bahwa penggunaan 3 fitur utama (CRP, Creatinine, dan ALT/AST) masih mampu mempertahankan performa yang mendekati model 5 fitur. Temuan ini memiliki implikasi praktis yang penting: di fasilitas kesehatan dengan sumber daya terbatas, pemeriksaan terhadap ketiga biomarker tersebut sudah cukup untuk mendukung proses skrining awal deteksi Hantavirus secara efisien.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, beberapa saran diajukan untuk pengembangan lebih lanjut:

1. Validasi dengan data nyata perlu dilakukan sebelum model diimplementasikan secara klinis. Dataset yang digunakan dalam penelitian ini merupakan data simulasi dari Kaggle, sehingga diperlukan pengujian menggunakan data rekam medis pasien aktual dari rumah sakit atau pusat kesehatan di daerah endemik Hantavirus untuk memverifikasi performa model pada kondisi nyata.
2. Eksplorasi algoritma lanjutan seperti Random Forest, LightGBM, atau metode deep learning (misalnya Neural Network tabular) dapat dilakukan untuk mengetahui apakah terdapat model yang mampu memberikan performa lebih tinggi, terutama dalam hal Recall kelas positif. Penggunaan teknik ensemble seperti stacking atau blending juga dapat menjadi alternatif yang menarik.
3. Penanganan ketidakseimbangan kelas (class imbalance) secara lebih mendalam dapat dieksplorasi lebih lanjut menggunakan teknik seperti SMOTE (Synthetic Minority Over-sampling Technique), ADASYN, atau class weighting pada algoritma. Pendekatan ini berpotensi meningkatkan sensitivitas model terhadap kelas positif yang merupakan kelas minoritas namun kritis.
4. Interpretabilitas model perlu ditingkatkan dengan mengintegrasikan metode SHAP (SHapley Additive exPlanations) atau LIME untuk memberikan penjelasan prediksi pada tingkat individual pasien. Hal ini penting agar model dapat diterima dan dipercaya oleh tenaga medis dalam pengambilan keputusan klinis.

5. Pengembangan antarmuka aplikasi berbasis web atau mobile yang mengintegrasikan model terpilih dapat menjadi langkah selanjutnya agar model dapat digunakan secara praktis oleh tenaga kesehatan di lapangan. Dengan memasukkan hasil pemeriksaan laboratorium rutin ke dalam sistem, prediksi risiko Hantavirus dapat diperoleh secara cepat dan mudah tanpa memerlukan keahlian khusus di bidang machine learning.

LAMPIRAN

Link Github : [https://github.com/Fatt-dev/Project Machine Learning Group B](https://github.com/Fatt-dev/Project_Machine_Learning_Group_B)

Link AI :

<https://claude.ai/share/c074ae14-9b3b-4559-8f32-e40b7dc773c4>

<https://share.gemini.google/7JEFsEs2OS33>